

INSTITUTO BRASILEIRO DE ENSINO, DESENVOLVIMENTO E PESQUISA

Programa de Pós-Graduação em Administração Pública
Mestrado Profissional

**ARQUITETURA DE IA GENERATIVA COM RAG E CÁLCULO DETERMINÍSTICO
PARA DEMOCRATIZAÇÃO DA ASSESSORIA EM RENDA FIXA NO BRB**

Kelsen de Moura Espíndola

Brasília-DF
2026

KELSEN DE MOURA ESPÍNDOLA

**ARQUITETURA DE IA GENERATIVA COM RAG E CÁLCULO DETERMINÍSTICO
PARA DEMOCRATIZAÇÃO DA ASSESSORIA EM RENDA FIXA NO BRB**

Dissertação apresentada à Escola de Administração Pública do Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa (IDP) como requisito para obtenção do título de Mestre em Administração Pública.

Orientador(a): Prof. Dr. Alex Lopes Pereira

Brasília-DF
2026

ESPÍNDOLA, Kelsen de Moura.

Arquitetura de IA Generativa com RAG e Cálculo Determinístico para Democratização da Assessoria em Renda Fixa no BRB / Kelsen de Moura Espíndola. – Brasília, [ANO DE DEPÓSITO].
38 f.

Dissertação (Mestrado Profissional em Administração Pública) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa, Escola de Administração Pública, [ANO DE DEPÓSITO].

Orientação: Prof. Dr. Alex Lopes Pereira.

1. Inteligência Artificial Generativa. 2. Retrieval-Augmented Generation. 3. Renda Fixa. 4. Bancos Públicos. 5. Administração Pública. I. Pereira, Alex Lopes. II. Título. _____

KELSEN DE MOURA ESPÍNDOLA

Matrícula: 25204263

**ARQUITETURA DE IA GENERATIVA COM RAG E CÁLCULO DETERMINÍSTICO
PARA DEMOCRATIZAÇÃO DA ASSESSORIA EM RENDA FIXA NO BRB**

Dissertação apresentada à Escola de Administração Pública
do Instituto Brasileiro de Ensino, Desenvolvimento e
Pesquisa (IDP) como requisito para obtenção do título de
Mestre em Administração Pública.

Brasília-DF, [dia] de [mês] de [ano]

Banca Examinadora

Prof. Dr. Alex Lopes Pereira
Orientador

Prof. Dr. Claudiomar Matias Rolim Filho
Avaliador

Prof. Dr. Danny de Castro Soares
Avaliador

[A ser preenchido pelo autor]

AGRADECIMENTOS

[A ser preenchido pelo autor]

RESUMO

[Versão preliminar – atualizar após a conclusão do backtesting e das avaliações empíricas, incluindo os principais resultados obtidos.]

O mercado de assessoria de investimentos no Brasil apresenta um duplo gargalo de distribuição: ferramentas automatizadas tradicionais limitam-se a questionários estáticos de suitability, enquanto modelos de Inteligência Artificial (IA) Generativa pura apresentam risco de alucinação matemática incompatível com um ambiente regulado. Nesse contexto, bancos públicos regionais como o Banco de Brasília (BRB) enfrentam um gargalo de capacidade estatal para escalar assessoria financeira qualificada ao seu público de perfil popular, em consonância com o mandato da Estratégia Nacional de Educação Financeira (ENEF). Esta pesquisa tem como objetivo geral desenvolver e validar uma arquitetura de IA Generativa baseada em agente único com function calling e recuperação de conhecimento (Retrieval-Augmented Generation – RAG), capaz de segregar o cálculo quantitativo determinístico, em Python, da geração de linguagem natural por Large Language Model (LLM), oferecendo orientação em investimentos de renda fixa a clientes pessoa física do BRB com precisão numérica verificável e conformidade à Resolução CVM nº 30/2021. A pesquisa adota abordagem multimétodos, apoiada na metodologia Design Science Research (DSR), combinando mapeamento qualitativo de demandas do investidor de varejo, desenvolvimento e validação técnica dos módulos de cálculo e da base de conhecimento regulatória, backtesting histórico de 12 meses e avaliação empírica por especialistas de mercado e gerentes de front-office. Espera-se demonstrar que a arquitetura proposta é capaz de produzir orientações tecnicamente adequadas, contribuindo tanto para a literatura de IA aplicada à Administração Pública quanto para a democratização prática do acesso à assessoria financeira de qualidade no varejo bancário público.

Palavras-chave: Inteligência Artificial Generativa; Retrieval-Augmented Generation; Assessoria Financeira; Bancos Públicos; Renda Fixa; Administração Pública.

ABSTRACT

Brazil's investment advisory market suffers from a twofold distribution gap: traditional automated tools are limited to static suitability questionnaires, while pure Generative Artificial Intelligence (AI) models present a risk of mathematical hallucination that is incompatible with a regulated environment. In this context, regional public banks such as Banco de Brasília (BRB) face a state-capacity bottleneck in scaling qualified financial advisory services to their retail client base, in line with the mandate of Brazil's National Strategy for Financial Education (ENEF). This research aims to develop and validate a Generative AI architecture based on a single agent with function calling and Retrieval-Augmented Generation (RAG), capable of segregating deterministic quantitative calculation, in Python, from natural-language generation by a Large Language Model (LLM), offering fixed-income investment guidance to BRB retail clients with verifiable numerical accuracy and compliance with CVM Resolution No. 30/2021. The research adopts a mixed-methods approach, grounded in the Design Science Research (DSR) methodology, combining qualitative mapping of retail investor needs, development and technical validation of the calculation modules and the regulatory knowledge base, a 12-month historical backtest, and empirical evaluation by market experts and front-office managers. The study expects to demonstrate that the proposed architecture is capable of producing technically adequate guidance, contributing both to the literature on AI applied to Public Administration and to the practical democratization of access to quality financial advisory services in public retail banking.

Keywords: Generative Artificial Intelligence; Retrieval-Augmented Generation; Financial Advisory; Public Banks; Fixed Income; Public Administration.

LISTA DE ILUSTRAÇÕES

LISTA DE TABELAS

LISTA DE QUADROS

4.1 Matriz de Opções Metodológicas 26

5.1 Síntese das Evidências sobre Barreiras Informacionais 27

7.1 Descritivo de Atividades e Prazos de Entrega 35

SUMÁRIO

LISTA DE ILUSTRAÇÕES	9
LISTA DE TABELAS	10
LISTA DE QUADROS	11
SUMÁRIO	13
1 Introdução	15
1.1 Contextualização Temática	15
1.2 Apresentação da Problemática e da Pergunta de Pesquisa	16
1.3 Enunciação dos Objetivos	17
1.3.1 Geral	17
1.3.2 Específicos	17
2 Referencial Teórico	19
2.1 Assimetria de Informação, Capacidade Estatal e a Natureza Dual dos Bancos Públicos	19
2.2 Retrieval-Augmented Generation e Conformidade Regulatória	19
2.3 Resolução CVM nº 30/2021, Governança Regulatória Bancária e Mitigação do Risco de Modelo	20
2.4 Explicabilidade Algorítmica (XAI) e Responsabilidade Civil	22
3 Hipóteses do Estudo	23
4 Metodologia	24
4.1 Natureza e Abordagem da Pesquisa	24
4.2 Fundamentação Empírica: Dados e Técnicas de Coleta	24
4.3 Técnicas de Análise dos Dados e Matriz de Opções Metodológicas	25
5 Resultados	27
5.1 Mapeamento das Barreiras Informacionais	27
5.1.1 Camada 1 – Pesquisa de Letramento Financeiro (BCB/FGC, 2023) . .	27
5.1.2 Camada 2 – Raio X do Investidor Brasileiro (ANBIMA)	28
5.1.3 Camada 3 – Reclame Aqui (Bancos Públicos)	28
6 Discussão	30
7 Conclusão	31

REFERÊNCIAS	32
ANEXOS	34
ANEXO I – Cronograma da Pesquisa (conforme planejado no pré-projeto)	35
ANEXO II – Personas Sintéticas de Investidor	36
ANEXO III – Instrumento de Avaliação Técnica	37
ANEXO IV – Questionário SUS	38

1 INTRODUÇÃO

1.1 Contextualização Temática

O Brasil atravessa uma transformação estrutural no mercado de investimentos. Segundo dados do Tesouro Nacional e do Banco Central do Brasil (BANCO CENTRAL DO BRASIL; TESOURO NACIONAL, 2025), o número de investidores pessoa física cadastrados no Tesouro Direto atingiu a marca de 33,25 milhões em agosto de 2025, registrando mais de 3,14 milhões de investidores ativos no mesmo período. Nesse movimento de digitalização, a 9ª edição do Raio X do Investidor Brasileiro (ANBIMA, 2026) identificou, pela primeira vez, o uso de assistentes de inteligência artificial como fonte de informação sobre produtos financeiros, mencionados por 9% dos investidores – à frente de canais tradicionais como rádio e e-mail.

No entanto, essa expansão quantitativa não foi acompanhada por uma democratização qualitativa: a orientação financeira personalizada e tecnicamente precisa permanece acessível predominantemente a clientes de alta renda, atendidos por assessores de bancos privados e corretoras digitais voltadas ao segmento premium. Ademais, modelos baseados exclusivamente em IA Generativa falham em tarefas financeiras que exigem precisão numérica devido à propensão a alucinações matemáticas – risco inaceitável em ambiente regulado –, conforme amplamente documentado na avaliação multitarefa de modelos de linguagem de larga escala (LLMs) por Bang et al. (2023).

A literatura recente documenta que modelos de linguagem de larga escala apresentam o fenômeno da alucinação confiante – geração de outputs factualmente incorretos com alto grau de verossimilhança e tom assertivo (BANG et al., 2023). Em domínios regulados como o Sistema Financeiro Nacional (SFN), onde a precisão de referências normativas é juridicamente exigível pela Resolução CVM nº 30/2021, esse comportamento representa risco operacional e legal inaceitável. Justifica-se, portanto, a necessidade científica e prática de uma arquitetura que segregue o processamento linguístico do processamento quantitativo determinístico.

Nesse contexto, os bancos públicos – em especial os de abrangência regional como o Banco de Brasília (BRB) – ocupam posição estratégica singular. Com mandato social de fomento ao desenvolvimento regional e ampla base de correntistas de perfil popular, essas instituições enfrentam uma tensão estrutural característica de sua natureza dual: precisam ser comercialmente eficientes e competitivas, ao mesmo tempo em que devem entregar o mandato social e de desenvolvimento que as distingue dos bancos privados (COSTA, 2016). A Estratégia Nacional de Educação Financeira (ENEF), instituída pelo Decreto nº 10.393/2020 (BRASIL, 2020), reforça esse mandato ao situar a promoção da educação financeira como política de Estado voltada à ampliação do acesso à orientação financeira de qualidade.

A escalabilidade dessa missão enfrenta um gargalo estrutural de capacidade estatal: a

impossibilidade prática de ampliar o quadro de especialistas na mesma proporção do crescimento da base de clientes. A Inteligência Artificial (IA) generativa, apoiada em ferramentas externas (function calling) e em bases de conhecimento indexadas (RAG), emerge, nesse contexto, como tecnologia capaz de resolver exatamente esse paradoxo – permitindo ao banco público entregar a política pública de inclusão financeira da ENEF em escala massiva no varejo, sem comprometer a eficiência administrativa e a conformidade regulatória exigidas pelo Banco Central.

1.2 Apresentação da Problemática e da Pergunta de Pesquisa

O mercado de assessoria de investimentos no Brasil sofre com um duplo gargalo de distribuição. De um lado, as ferramentas automatizadas tradicionais – os chamados robôs-investidores – limitam-se a sugerir alocações baseadas em questionários estáticos de suitability, ignorando mudanças dinâmicas na curva de juros e as restrições de liquidez do cidadão comum. De outro lado, a dependência exclusiva de LLMs puros acarreta sérios riscos de integridade nas estimativas patrimoniais, dado o fenômeno da alucinação confiante documentado na literatura.

A lacuna identificada é significativa. Embora estudos internacionais tenham explorado o uso de LLMs em análise de sentimento financeiro (LOPEZ-LIRA; TANG, 2023) ou robôs-consultores baseados em regras (D’ACUNTO; PRABHALA; ROSSI, 2019), não foram identificados estudos que proponham e avaliem uma arquitetura de IA Generativa que integre cálculo quantitativo determinístico com geração de linguagem natural para orientação de investidores de varejo em bancos públicos brasileiros, com plena conformidade ao arcabouço regulatório nacional.

A contribuição desta pesquisa é dupla: para a dimensão prática da Administração Pública, ao propor solução escalável para democratizar o acesso à assessoria financeira; e para a literatura especializada, ao desenvolver e avaliar empiricamente uma arquitetura original de IA Generativa com cálculo determinístico e recuperação de conhecimento regulatório (RAG) no contexto brasileiro.

Diante do exposto, a pergunta de pesquisa que orienta este estudo é:

Uma arquitetura de IA Generativa baseada em agente único que, por meio de function calling, separa o cálculo quantitativo em Python da geração de linguagem por LLM e recupera normativos vigentes de uma base de conhecimento regulatório (RAG), é capaz de oferecer orientação em investimentos de renda fixa para clientes pessoa física do BRB com precisão numérica verificável e conformidade à Resolução CVM nº 30/2021, sendo avaliada como tecnicamente adequada por especialistas de mercado em avaliação técnica estruturada?

1.3 Enunciação dos Objetivos

1.3.1 Geral

Desenvolver e validar uma arquitetura de IA Generativa, baseada em agente único com function calling e recuperação de conhecimento (RAG), capaz de automatizar a análise macroeconômica, o cálculo quantitativo de ativos e a orientação em investimentos de renda fixa para clientes pessoa física do BRB, com foco em acessibilidade, precisão numérica verificável e conformidade regulatória à Resolução CVM nº 30/2021, no período 2026-2027.

1.3.2 Específicos

- (a) Mapear as principais barreiras informacionais e dúvidas recorrentes do investidor de perfil popular a partir de bases públicas online – combinando a Pesquisa de Letramento Financeiro do Banco Central do Brasil (metodologia OCDE/INFE) como evidência estatística nacionalmente representativa, o Raio X do Investidor Brasileiro (ANBIMA) como fonte complementar de padrões comportamentais, e registros do Reclame Aqui de bancos públicos comerciais de varejo (Banco do Brasil, Caixa Econômica Federal, BRB, Banrisul, Banestes, Banese e Banpará) como evidência ilustrativa –, por meio de análise estatística descritiva e de análise de conteúdo categorial dos registros disponíveis.
- (b) Projetar uma arquitetura de agente único baseada em LLM com function calling, integrando
 - (i) um módulo determinístico em Python puro para o processamento numérico e (ii) uma base de conhecimento regulatória indexada via Retrieval-Augmented Generation (RAG, “wiki” normativa), separando o processamento numérico da geração de linguagem natural e gerando logs estruturados de explicabilidade (XAI) para cumprimento do Princípio da Motivação.
- (c) Desenvolver módulos matemáticos em Python para cálculo exato de rentabilidade líquida – parametrizando a ordem de prioridade tributária de incidência do IOF antes do Imposto de Renda para resgates em prazos inferiores a 30 dias –, duration e comparação entre CDB e Tesouro Direto, integrados a APIs públicas do BCB e ANBIMA, com validação por testes unitários de casos-limite ($t = 0$, $t = 29$ e $t = 30$ dias na fronteira de incidência do IOF, taxa de rendimento nula) e por validação cruzada dos resultados frente a simuladores oficiais (Tesouro Transparente, calculadoras ANBIMA), assegurando que o padrão de referência (*ground truth*) utilizado no backtesting seja independentemente verificado.
- (d) Construir base de conhecimento regulatória via Retrieval-Augmented Generation (RAG) com normativos da CVM, CMN, Tesouro Nacional e ANBIMA, com guardrails algorítmicos baseados nas resoluções vigentes, indexando cada trecho normativo (*chunk*) com metadados de vigência – data de publicação, status vigente/revogado e norma revogadora, quando aplicável – para que o agente priorize automaticamente o dispositivo em vigor e descarte referências a normas superadas.

- (e) Realizar backtesting em janela histórica de 12 meses (junho/2025 a maio/2026) e avaliar a qualidade das respostas – geradas para um conjunto de personas sintéticas de investidor – por meio de avaliação técnica com especialistas e teste de usabilidade com gerentes de front-office do BRB.

2 REFERENCIAL TEÓRICO

2.1 Assimetria de Informação, Capacidade Estatal e a Natureza Dual dos Bancos Públicos

A teoria da assimetria de informação, formalizada por Akerlof (1970) e Stiglitz e Weiss (1981), encontra aplicação direta no mercado de investimentos quando investidores de varejo tomam decisões sem acesso às mesmas informações disponíveis a intermediários financeiros profissionais.

No contexto brasileiro, o Raio X do Investidor Brasileiro da ANBIMA (ANBIMA, 2025) e o Relatório de Cidadania Financeira do Banco Central (BANCO CENTRAL DO BRASIL, 2023) documentam que parcela expressiva dos investidores pessoa física mantém seus recursos em produtos de baixa rentabilidade – como a caderneta de poupança –, situação associada, entre outros fatores, ao desconhecimento das alternativas disponíveis no mercado.

Bancos públicos como o BRB, o Banco do Brasil e a Caixa Econômica Federal atendem segmentos populacionais historicamente excluídos do sistema financeiro sofisticado. Segundo Costa (2016), esses bancos operam sob uma tensão estrutural característica de sua natureza dual: precisam ser comercialmente eficientes e competitivos como os bancos privados, mas simultaneamente devem cumprir mandato redistributivo que transcende a intermediação financeira, funcionando como vetores de inclusão econômica. A arquitetura proposta neste trabalho resolve exatamente esse paradoxo: permite ao BRB entregar a política pública de inclusão financeira da ENEF em escala massiva no varejo, sem explodir os custos operacionais, mantendo a eficiência administrativa e a conformidade exigidas pelo Banco Central.

Essa dimensão conecta-se ao conceito de capacidade estatal – a habilidade do Estado de formular e implementar políticas públicas com qualidade e escala (EVANS; RAUCH, 1999). A incapacidade do BRB de escalar a assessoria financeira qualificada sem suporte tecnológico é, fundamentalmente, um problema de capacidade estatal, não apenas operacional. O artefato desenvolvido nesta pesquisa busca ampliar essa capacidade de forma replicável, com potencial de subsidiar diretrizes para políticas de inclusão financeira no âmbito da ENEF (Decreto nº 10.393/2020).

2.2 Retrieval-Augmented Generation e Conformidade Regulatória

A técnica de Retrieval-Augmented Generation (RAG), proposta por Lewis et al. (2020), consiste em enriquecer o contexto do LLM com documentos recuperados de uma base de conhecimento indexada, reduzindo o risco de alucinações e atualizando o conhecimento do modelo sem re-treinamento. A capacidade de modelos de linguagem de utilizarem ferramentas computacionais externas de forma autônoma para resolver problemas complexos (SCHICK et al.,

2023) fundamenta o acoplamento, via function calling, do módulo de cálculo quantitativo.

Para a orquestração de chamadas a ferramentas externas (function calling) e para a recuperação de conteúdo indexado, o uso de frameworks especializados como LangChain (CHASE, 2023) viabiliza a estruturação modular da aplicação. A capacidade de um agente LLM único invocar de forma autônoma ferramentas determinísticas externas para resolver subtarefas específicas – como cálculos matemáticos – tende a produzir resultados mais confiáveis do que a geração da resposta inteiramente dentro do próprio modelo de linguagem (SCHICK et al., 2023).

No domínio financeiro-regulatório brasileiro, a aplicação de RAG sobre normativos da CVM, resoluções do CMN e manuais da ANBIMA permite ao agente responder perguntas sobre regras tributárias, prazos de carência e critérios de elegibilidade com fundamentação documental rastreável – requisito essencial para conformidade com a Resolução CVM nº 30/2021, que regulamenta o dever de verificação da adequação dos produtos, serviços e operações ao perfil do cliente.

2.3 Resolução CVM nº 30/2021, Governança Regulatória Bancária e Mitigação do Risco de Modelo

A Resolução CVM nº 30/2021 (RESOLUÇÃO... , 2021) estabelece o dever de verificação da adequação dos produtos, serviços e operações ao perfil do cliente (*suitability*). Em conformidade com o art. 3º deste normativo, as instituições devem avaliar de forma pormenorizada e independente três dimensões do investidor: (i) os objetivos de investimento; (ii) a situação financeira; e (iii) o conhecimento sobre os riscos do produto.

No contexto de uma assessoria financeira automatizada por inteligência artificial, o cumprimento desses requisitos regulatórios e o controle dos riscos envolvidos apoiam-se em um conjunto de resoluções emitidas pelo Conselho Monetário Nacional (CMN) e pelo Banco Central do Brasil:

- **Resolução CMN nº 4.557/2017 (RESOLUÇÃO... , 2017) – Gerenciamento de Riscos:** esta norma define a obrigatoriedade de estruturação integrada da gestão de riscos bancários, incluindo diretrizes para a governança, integridade e validação de modelos. A segregação técnica estrita entre o processamento matemático numérico (módulo Python acionado via function calling) e a geração linguística da LLM atua como controle estrutural exigido pela 4.557/2017 para mitigar o risco de modelo.
- **Resolução CMN nº 4.968/2021 (RESOLUÇÃO... , 2021) – Sistemas de Controles Internos:** os controles internos preventivos de conformidade algorítmica são codificados no agente para atuar como guardrails ativos de *suitability*, impossibilitando fisicamente que a LLM proponha ativos desalinhados ao perfil de risco declarado do investidor.
- **Resolução CMN nº 4.879/2020 (RESOLUÇÃO... , 2020) – Auditoria Interna:** regulamenta a auditoria interna como terceira linha de defesa independente, responsável por

revisar periodicamente a efetividade operacional de todo o fluxo do sistema. Os logs de XAI gerados pelo agente fornecem a trilha de auditoria necessária para esse escrutínio.

- **Resoluções CMN nº 4.893/2021 e 5.274/2025 (RESOLUÇÃO..., 2021; RESOLUÇÃO..., 2025) – Segurança Cibernética e Nuvem:** o software de IA no BRB deve incorporar controles técnicos auditáveis exigidos pela Resolução CMN nº 4.893/2021 e detalhados em 14 procedimentos e controles mínimos pela Resolução CMN nº 5.274/2025, incluindo criptografia em trânsito e repouso, mecanismos de DLP para chamadas de APIs externas de LLM, logs de rastreabilidade imutáveis do agente e autenticação multifatorial (MFA) para acessos administrativos.

A infraestrutura do agente (LLM) adotará o consumo de modelo via API comercial externa. Essa escolha prioriza a agilidade de implementação e o acesso a modelos de fronteira mais capazes, compatível com o cronograma do mestrado profissional, e é viabilizada pelo uso exclusivo de personas sintéticas na avaliação do sistema (objetivo específico e; seção 4.2), o que dispensa mecanismos de DLP para dados pessoais em trânsito nesta fase da pesquisa. A criptografia em trânsito e os demais controles técnicos exigidos pelas Resoluções CMN nº 4.893/2021 e 5.274/2025 permanecem aplicáveis independentemente dessa decisão. A eventual migração para hospedagem de modelo de pesos abertos on-premise – hipótese a ser considerada caso o sistema venha a processar dados reais de clientes em fase posterior – fica registrada como agenda de pesquisa futura, fora do escopo desta dissertação.

Sob o prisma da modelagem matemática e financeira, a simulação do retorno final líquido acumulado (RFL) é processada de forma determinística pelo módulo Python de cálculo, acionado via function calling, com dois cenários estruturais condicionados ao prazo de aplicação t :

$$\text{RFL} = P_0 \cdot [(1 + i)^t - 1] \cdot (1 - \theta) - C_o \quad (\text{para } t \geq 30 \text{ dias}) \quad (2.1)$$

$$\text{RFL} = P_0 \cdot [(1 + i)^t - 1] \cdot (1 - \alpha_t) \cdot (1 - \theta) - C_o \quad (\text{para } t < 30 \text{ dias}) \quad (2.2)$$

Em que: RFL é o retorno final líquido acumulado; P_0 representa o principal investido; i é a taxa de rendimento nominal acumulada por período; t é o número de períodos de capitalização; α_t é a alíquota regressiva do IOF ($\alpha_t = 0$ para $t \geq 30$); θ é a alíquota regressiva do IR (variando de 22,5% a 15%); e C_o é o somatório dos custos operacionais e taxas de administração.

A janela de 12 meses (junho/2025 a maio/2026) foi delimitada por coincidir com um período de relevante volatilidade macroeconômica na curva de juros brasileira, garantindo disponibilidade integral de dados históricos via APIs do BCB e da ANBIMA para os produtos avaliados (CDB e Tesouro Direto).

2.4 Explicabilidade Algorítmica (XAI) e Responsabilidade Civil

No setor público, decisões ou recomendações geradas por sistemas de IA que afetam o patrimônio do cidadão estão sujeitas ao Princípio da Motivação dos Atos Administrativos (Arts. 2º e 50 da Lei Federal nº 9.784/1999 (BRASIL, 1999)), aplicável à administração pública do Distrito Federal por força da Lei Distrital nº 2.834/2001 (DISTRITO FEDERAL, 2001). Isso impõe que o sistema seja capaz de explicitar, de forma rastreável, o fundamento de cada recomendação emitida.

Para atender ao Princípio da Motivação, o agente gerará, além da resposta em linguagem natural ao cliente, um log estruturado de justificativa (registro XAI), documentando os parâmetros utilizados – taxa, prazo, alíquota tributária e regra de suitability aplicada – que fundamentaram cada orientação.

No plano da responsabilidade civil, eventuais erros do artefato que causem dano patrimonial ao cliente atraem a responsabilidade objetiva do BRB, nos termos do Art. 14 do Código de Defesa do Consumidor (CDC) – aplicável às instituições financeiras conforme pacificado pela Súmula 297 do STJ (SUPERIOR TRIBUNAL DE JUSTIÇA, 2004). A evolução desse quadro de responsabilidade, especialmente no que tange à graduação de riscos de sistemas de IA de alto risco, deverá ser acompanhada à luz da tramitação do Projeto de Lei nº 2.338/2023 (SENADO FEDERAL, 2023) (Marco Legal da IA), que constitui agenda de pesquisa futura.

3 HIPÓTESES DO ESTUDO

H1 – A arquitetura proposta gerará orientações em renda fixa com precisão numérica verificável (cálculos de rentabilidade líquida, impacto de IR/IOF e duration) e conformidade regulatória comprovada, demonstrando viabilidade como ferramenta de assessoria automatizada em ambiente regulado.

Fundamentação: estudos sobre robôs-consultores (D’ACUNTO; PRABHALA; ROSSI, 2019) documentam que modelos algorítmicos reduzem os vieses comportamentais humanos de tomada de decisão. A segregação entre cálculo composto determinístico (Python) e geração de linguagem (LLM) elimina a principal fonte de erro em modelos generativos puros – as alucinações matemáticas –, conferindo auditabilidade integral às saídas. A precisão numérica é aferida frente ao padrão de referência (*ground truth*) independentemente verificado nos simuladores oficiais (Tesouro Transparente, calculadoras ANBIMA), conforme detalhado no objetivo específico c, dispensando a necessidade de um comparador externo.

H2 – A avaliação das recomendações do agente por gerentes de front-office do BRB – aplicada via questionário System Usability Scale (SUS) nos critérios de clareza, precisão e adequação regulatória – atingirá score SUS igual ou superior a 68 pontos, classificado na literatura como patamar “Aceitável/Bom” (BANGOR; KORTUM; MILLER, 2008; SAURO, 2011).

Fundamentação: a hipótese apoia-se na identificação de lacunas na qualidade e profundidade da assessoria nos canais físicos de varejo, frequentemente decorrentes da sobrecarga operacional dos gerentes comerciais. Um agente de software especializado, com acesso instantâneo a todas as curvas de juros e resoluções aplicáveis, tende a produzir recomendações mais robustas para carteiras padrão. O score SUS de 68 pontos (escala de 0 a 100) é o limiar empírico estabelecido na literatura como patamar mínimo de aceitabilidade de sistemas interativos, calculado pela metodologia padrão do questionário (soma das pontuações convertidas dos 10 itens). O instrumento será aplicado em sua forma original, sem conversão para escalas alternativas.

H3 – O framework desenvolvido no BRB apresentará arquitetura modular suficientemente desacoplada de especificidades institucionais para ser adaptado a outros bancos públicos estaduais, com esforço de customização restrito aos módulos de integração de dados internos e parametrização regulatória local, indicando potencial de escala para políticas públicas de inclusão financeira no âmbito da ENEF.

Fundamentação: a modularidade da arquitetura, apoiada em APIs públicas (BCB/ANBIMA) e no mapeamento de demandas de varejo via bases públicas online, reduz significativamente as amarras sistêmicas corporativas da aplicação, facilitando a transposição do modelo para estruturas bancárias congêneres e sua eventual incorporação como diretriz de política pública.

4 METODOLOGIA

4.1 Natureza e Abordagem da Pesquisa

Esta pesquisa adota abordagem multimétodos (*mixed methods*), combinando dimensões qualitativa e quantitativa em etapas sequenciais e complementares, conforme proposto por John W. Creswell e J. David Creswell (2018) para pesquisas aplicadas em Administração Pública. A natureza da pesquisa é aplicada e de caráter exploratório-descritivo.

A estratégia de pesquisa segue a metodologia Design Science Research (DSR), proposta por Hevner et al. (2004), especialmente adequada para pesquisas de Sistemas de Informação e Administração Pública que envolvem desenvolvimento de artefatos tecnológicos com impacto organizacional, por exigir que o artefato resolva um problema real, identificado empiricamente, e seja avaliado por critérios de utilidade e rigor científico.

4.2 Fundamentação Empírica: Dados e Técnicas de Coleta

A pesquisa utilizará dados primários e secundários em combinação.

- A Pesquisa de Letramento Financeiro (Banco Central do Brasil em parceria com o Fundo Garantidor de Créditos, metodologia OCDE/INFE) (BANCO CENTRAL DO BRASIL; FUNDO GARANTIDOR DE CRÉDITOS, 2023), que fornece evidência estatística nacionalmente representativa sobre o conhecimento da população acerca de produtos de renda fixa; o Raio X do Investidor Brasileiro (ANBIMA), como fonte complementar de padrões de comportamento do investidor de varejo; e registros públicos do Reclame Aqui, filtrados pelo conjunto de bancos públicos comerciais de varejo do Brasil – Banco do Brasil e Caixa Econômica Federal (federais) e BRB, Banrisul, Banestes, Banese e Banpará (estaduais/distrital, sobreviventes do Programa de Incentivo à Redução do Setor Público Estadual na Atividade Bancária – PROES) – e por vinculação a decisão ativa de investimento, como evidência ilustrativa da manifestação prática dessas barreiras. A condição de controle público de cada instituição foi verificada em agosto de 2026. Os padrões de dúvidas identificados nos registros do Reclame Aqui são analisados via análise de conteúdo categorial (BARDIN, 2011), complementando a análise estatística descritiva da Pesquisa de Letramento Financeiro, e fortalecendo a validade dos dados sem exigir acesso direto aos clientes.
- Séries históricas extraídas via API do SGS/Banco Central (taxas de juros, índices de inflação, expectativas Focus); preços e taxas diários do Tesouro Transparente; taxas de mercado da ANBIMA; normativos e resoluções da CVM e do CMN, incluindo o PL nº 2.338/2023 (Marco Legal da IA) como referência de governança prospectiva. Todos os

dados secundários são de acesso público e gratuito.

Para a etapa de avaliação (objetivo específico e), o sistema será testado com personas sintéticas – perfis de investidor fictícios, não vinculados a dados reais de clientes do BRB – construídas em duas camadas. A estrutura segue as três dimensões de suitability da Resolução CVM nº 30/2021 (objetivos de investimento, situação financeira e conhecimento sobre os riscos), garantindo cobertura sistemática do espaço de teste regulatório. Os valores de calibração de cada persona (faixa etária, renda, nível de conhecimento financeiro) são ancorados nos quatro perfis comportamentais publicados na 8ª edição do Raio X do Investidor Brasileiro (ANBIMA, 2025) – Diversifica, Caderneta, Economiza e Não Investe, e Sem Reservas –, preservando a representatividade do público de perfil popular que é o foco do BRB. As fontes utilizadas no mapeamento de dores do objetivo específico (a) – Pesquisa de Letramento Financeiro, Raio X do Investidor e Reclame Aqui – não são utilizadas na construção das personas, por consistirem em dados agregados ou de terceiros, sem perfil individual atribuível. Essa abordagem dispensa o uso de dados reais de clientes em qualquer etapa da pesquisa.

4.3 Técnicas de Análise dos Dados e Matriz de Opções Metodológicas

As técnicas de análise variam conforme a etapa da pesquisa. Na Etapa 1, serão combinadas análise estatística descritiva sobre a Pesquisa de Letramento Financeiro e análise de conteúdo categorial (BARDIN, 2011) sobre registros do Reclame Aqui. Na fase quantitativa de backtesting (Etapa 4), serão calculadas métricas de desempenho: retorno líquido acumulado e frequência de superação do CDI em janelas mensais. O cálculo do Sharpe ratio será realizado com a devida ressalva metodológica de que a janela de 12 meses, embora necessária para viabilizar o cálculo do indicador dentro do período disponível, impõe limitações ao poder de generalização estatística dos indicadores de volatilidade – limitação que será explicitamente reconhecida no capítulo de limitações do estudo. Na fase de avaliação (Etapa 5), serão aplicadas estatística descritiva sobre notas da avaliação técnica e análise de conteúdo sobre os comentários qualitativos.

Rubrica da avaliação técnica. Para operacionalizar H1 e H2 com maior granularidade, a avaliação técnica adotará rubrica de avaliação estruturada em três pilares quantificáveis, pontuados individualmente por cada especialista em escala Likert de 5 pontos: (i) fidelidade do Retorno Final Líquido (RFL) reportado na resposta ao cliente frente ao valor calculado pelo módulo determinístico – não uma reavaliação da matemática do módulo, já verificada no objetivo específico c –, incluindo a correta aplicação da alíquota regressiva do IR (θ) e da alíquota do IOF; (ii) aderência da recomendação às regras de suitability vigentes (Resolução CVM nº 30/2021); e (iii) clareza da linguagem da resposta ao cliente. Essa rubrica complementa – sem substituir – o questionário SUS previsto em H2, permitindo diagnosticar separadamente falhas de fidelidade na síntese linguística, de conformidade regulatória e de usabilidade. Para preservar a independência da avaliação técnica, os especialistas responsáveis por ela serão profissionais de mercado não vinculados ao BRB, distintos dos gerentes de front-office que participam da

etapa de validação de usabilidade, evitando a sobreposição entre avaliação técnica independente e aceitação organizacional interna.

Validação da base RAG. A cobertura e o recall da base de conhecimento regulatória (objetivo específico d) serão avaliados por meio de um conjunto de teste de 30 a 50 perguntas sobre normativos da CVM, do CMN e da ANBIMA, com respostas gabaritadas manualmente, permitindo calcular recall@k e precisão da recuperação documental antes da integração da base ao agente. Adicionalmente, o mecanismo de metadados de vigência descrito no objetivo específico d será testado com um subconjunto de perguntas envolvendo dispositivos normativos revogados ou alterados, verificando se o sistema prioriza corretamente a norma vigente.

Quadro 4.1 – Matriz de Opções Metodológicas

Objetivos específicos	Abordagem	Natureza	Dados	Público-alvo	Coleta	Análise
a) Mapear barreiras informacionais	Qualitativa	Exploratória	Secundários (públicos online)	Survey BCB/FGC; ANBIMA; Reclame Aqui	Extração de dados públicos	Estatística descritiva e de conteúdo
b) Projetar arquitetura de agente único	Qualitativa	Descritiva	Secundários	Documentos regulatórios	Análise documental	Síntese qualitativa
c) Desenvolver módulos Python	Quantitativa	Aplicada	Secundários	APIs BCB/ANBIMA	Extração via API	Teste de precisão
d) Construir base RAG	Qualitativa	Descritiva	Secundários	Normativos CVM/CMN	Indexação vetorial	Cobertura e recall
e) Backtesting e avaliação	Multimétodos	Descritiva	Primários e secundários	Especialistas BRB + dados históricos	Avaliação técnica + simulação	Estatística descritiva

Fonte: Elaborado pelo autor (2026).

5 RESULTADOS

Esta seção apresenta os resultados preliminares do diagnóstico de barreiras informacionais e dúvidas recorrentes do investidor de perfil popular, executado na fase de Diagnóstico do cronograma da pesquisa (Anexo I, ago.–out. 2026). Os achados constituem resultados parciais, sujeitos a aprofundamento; as seções 5.2 a 5.5 permanecem pendentes, por dependerem de etapas empíricas futuras (engenharia dos módulos Python, construção da base RAG, backtesting e validação com especialistas e gerentes).

5.1 Mapeamento das Barreiras Informacionais

A estratégia de coleta combinou três camadas de evidência, da mais robusta estatisticamente à mais ilustrativa, sintetizadas no Quadro 5.1.

Quadro 5.1 – Síntese das Evidências sobre Barreiras Informacionais

Camada	Fonte	Papel	Tipo de evidência
1 – Principal	Pesquisa de Letramento Financeiro (BCB/FGC, 2023)	Quantificar a barreira de forma estatisticamente representativa	Survey nacional, N=2.000, IC 95%
2 – Complementar	Raio X do Investidor Brasileiro (ANBIMA, 2025/2026)	Perfis comportamentais e tendências populacionais	Survey anual (Datafolha), N≈5.800
3 – Ilustrativa	Reclame Aqui (7 bancos públicos, registros filtrados)	Ilustrar a manifestação prática da barreira	Análise de conteúdo qualitativa (BARDIN, 2011)

Fonte: Elaborado pelo autor (2026).

5.1.1 Camada 1 – Pesquisa de Letramento Financeiro (BCB/FGC, 2023)

A evidência quantitativa central do diagnóstico provém da Pesquisa de Letramento Financeiro, conduzida pelo Banco Central do Brasil (BCB) em parceria com o Fundo Garantidor de Créditos (FGC), com metodologia padronizada internacionalmente pelo Toolkit OCDE/INFE (BANCO CENTRAL DO BRASIL; FUNDO GARANTIDOR DE CRÉDITOS, 2023) (2.000 entrevistas, amostra probabilística estratificada, intervalo de confiança de 95%, margem de erro de 2,19%). Os resultados indicam que apenas 48,2% da população brasileira já ouviu falar de “Títulos financeiros (como Tesouro Direto ou CDBs)” – a categoria de produto financeiro com menor índice de conhecimento entre as testadas, à frente apenas de conta de investimento (31,0%) e produtos classificados como sustentáveis (16,6%). Entre os entrevistados que pouparam nos últimos doze meses, apenas 7,1% aplicaram em Tesouro Direto ou CDB, contra 43,0% que utilizaram caderneta de poupança ou conta corrente.

Mais relevante ainda para a arquitetura proposta é o resultado da dimensão de conhecimento financeiro mensurado – isto é, aferido por meio de questões de cálculo, e não por autodeclaração. Embora 83,9% dos entrevistados demonstrem compreender a noção geral de juros, apenas 14,3% conseguiram calcular corretamente um problema de juros simples, e apenas 46,6% responderam corretamente sobre a implicação de juros compostos. Esse descolamento entre compreender o conceito e conseguir operá-lo numericamente corrobora, com dados primários e representatividade nacional, a justificativa científica apresentada na Introdução para a segregação entre processamento numérico determinístico e geração de linguagem natural.

5.1.2 Camada 2 – Raio X do Investidor Brasileiro (ANBIMA)

A 8ª edição do Raio X do Investidor Brasileiro (ANBIMA, 2025) fundamenta a segmentação comportamental em quatro perfis já utilizada para calibrar as personas sintéticas do Anexo II. A 9ª edição (ANBIMA, 2026) acrescenta um dado relevante ao diagnóstico: do total de brasileiros que conseguiram poupar em 2025, apenas 12% efetivamente converteram a poupança em investimento, evidenciando o funil poupança–investimento como gargalo estrutural que antecede a própria decisão sobre qual produto de renda fixa escolher.

5.1.3 Camada 3 – Reclame Aqui (Bancos Públicos)

Como camada ilustrativa, foi conduzida análise de conteúdo qualitativa (BARDIN, 2011) sobre registros públicos do Reclame Aqui filtrados pelo conjunto de sete bancos públicos comerciais de varejo do Brasil – Banco do Brasil, Caixa Econômica Federal, BRB, Banrisul, Banestes, Banese e Banpará – e por vinculação a decisão ativa de investimento em CDB ou Tesouro Direto, excluindo-se registros relativos a produtos de aplicação automática sobre saldo em conta corrente (ex.: CDB Salário no BRB, CDB Automático no Banrisul), que não configuram decisão de investimento por parte do cliente. O uso do Reclame Aqui como fonte de pesquisa acadêmica encontra precedente metodológico em Rímoli e Melo (2018). A amostra resultante, reduzida e não probabilística, não deve ser lida como representativa – seu papel é ilustrar, com casos concretos, como as barreiras identificadas nas Camadas 1 e 2 se manifestam na jornada real do investidor de perfil popular em bancos públicos. O conteúdo relevante concentrou-se em três das sete instituições (Banco do Brasil, Caixa e BRB); Banestes, Banese e Banpará não apresentaram registros indexados publicamente sobre CDB ou Tesouro Direto no período consultado, e o Banrisul apresentou majoritariamente registros sobre seu produto de aplicação automática, excluídos pelo mesmo critério aplicado ao CDB Salário. Emergiram cinco categorias recorrentes: (i) confusão sobre o processo de cadastro e liquidação via CBLC/B3 para operar Tesouro Direto pelo banco – a categoria mais saturada, presente de forma independente no Banco do Brasil e na Caixa, com relatos recorrentes de mensagens como “aguardando retorno da CBLC” interpretadas como falha do sistema; (ii) fricção e custos ocultos ao diversificar investimentos por meio de corretora parceira (BRB); (iii) desconhecimento sobre a renovação automática (*rollover*) do CDB no vencimento (BRB); (iv) falta de transparência sobre o status do investimento no

aplicativo (BRB); e (v) desconhecimento sobre janelas operacionais de resgate (BRB, Caixa).

Não foi localizado, na literatura revisada, artigo com revisão por pares que combine análise de conteúdo de reclamações, renda fixa e barreiras do investidor de perfil popular, o que indica uma lacuna que esta pesquisa contribui para preencher.

Síntese integradora. As três camadas de evidência, tomadas em conjunto, permitem hierarquizar as barreiras informacionais identificadas da mais estrutural à mais operacional. No topo está uma barreira de conhecimento básico: 51,8% da população brasileira sequer reconhece os termos “Tesouro Direto” ou “CDB” (Camada 1), o que precede logicamente qualquer dúvida mais específica sobre esses produtos. Em seguida, uma barreira de operação numérica: mesmo entre quem compreende a noção geral de juros, apenas 14,3% sabe calculá-los corretamente (Camada 1) – gargalo que a arquitetura proposta endereça diretamente ao segregar o cálculo determinístico da geração de linguagem. Uma terceira barreira é de acesso: do público que consegue poupar, apenas 12% converte a poupança em investimento (Camada 2), evidenciando atrito na transição entre poupar e investir que antecede a escolha do produto. Por fim, duas barreiras operacionais específicas e recorrentes aparecem na Camada 3, ambas observadas em mais de uma instituição: a confusão sobre o processo de cadastro e liquidação via CBLIC/B3 para operar Tesouro Direto pelo banco (Banco do Brasil e Caixa) e o desconhecimento sobre janelas operacionais de resgate (BRB e Caixa) – o que lhes confere maior robustez do que as demais três categorias da mesma camada, cada uma restrita a um único registro no BRB. Essa hierarquia – conhecimento básico → operação numérica → acesso → fricção operacional específica – fornece o insumo prioritário para a calibração das personas sintéticas (Anexo II) e para a definição do escopo inicial da base de conhecimento regulatória do agente (objetivo específico b).

As demais seções deste capítulo permanecem pendentes, a serem redigidas após a execução empírica prevista no cronograma (Anexo I):

5.2. Arquitetura do agente e módulos Python – validação técnica (objetivos b e c) [PENDENTE]

5.3. Base de conhecimento regulatória RAG – recall@k e priorização de norma vigente (objetivo d) [PENDENTE]

5.4. Resultados do backtesting de 12 meses (jun/25–mai/26) [PENDENTE]

5.5. Avaliação técnica dos especialistas e resultado do questionário SUS (objetivo e) [PENDENTE]

6 DISCUSSÃO

[Capítulo pendente – a ser redigido após a execução empírica prevista no cronograma (Anexo I). Estrutura sugerida:]

6.1. Teste das hipóteses H1, H2 e H3 à luz dos resultados

6.2. Diálogo com o referencial teórico (assimetria de informação, capacidade estatal, RAG, XAI)

6.3. Limitações do estudo (ex.: Sharpe ratio em janela de 12 meses)

7 CONCLUSÃO

[Capítulo pendente – a ser redigido após a execução empírica prevista no cronograma (Anexo I). Estrutura sugerida:]

7.1. Síntese dos achados e contribuições para a Administração Pública

7.2. Potencial de escala para outros bancos públicos (H3) e para políticas de inclusão financeira (ENEF)

7.3. Agenda de pesquisa futura

REFERÊNCIAS

- AKERLOF, G. A. The market for lemons: quality uncertainty and the market mechanism. **The Quarterly Journal of Economics**, v. 84, n. 3, p. 488–500, 1970.
- ANBIMA. **Raio X do Investidor Brasileiro: 8ª edição**. Rio de Janeiro, 2025.
- _____. **Raio X do Investidor Brasileiro: 9ª edição**. Rio de Janeiro, 2026.
- BANCO CENTRAL DO BRASIL. **Relatório de Cidadania Financeira**. Brasília, 2023.
- BANCO CENTRAL DO BRASIL; FUNDO GARANTIDOR DE CRÉDITOS. **Pesquisa de Letramento Financeiro: relatório de resultados. Metodologia OCDE/INFE**. Brasília, 2023.
- BANCO CENTRAL DO BRASIL; TESOURO NACIONAL. **Tesouro Direto: estatísticas e dados de investidores cadastrados e ativos de agosto de 2025**. Brasília, 2025.
- BANG, Y. et al. **A multitask, multilingual, multimodal evaluation of ChatGPT on reasoning, hallucination, and interactivity**. 2023. arXiv: 2302.04023.
- BANGOR, A.; KORTUM, P. T.; MILLER, J. T. An empirical evaluation of the System Usability Scale. **International Journal of Human-Computer Interaction**, v. 24, n. 6, p. 574–594, 2008.
- BARDIN, L. **Análise de conteúdo**. São Paulo: Edições 70, 2011.
- BRASIL. **Decreto nº 10.393, de 9 de junho de 2020. Institui a nova Estratégia Nacional de Educação Financeira**. Brasília: Presidência da República, 2020.
- _____. **Lei nº 9.784, de 29 de janeiro de 1999. Regula o processo administrativo no âmbito da Administração Pública Federal**. Brasília: Presidência da República, 1999.
- CHASE, H. **LangChain: Building applications with LLMs through composability**. 2023. Disponível em: <<https://github.com/langchain-ai/langchain>>. Acesso em: 5 ago. 2026.
- COSTA, F. N. d. **Bancos Públicos no Brasil**. São Paulo: Editora Fundação Perseu Abramo, 2016.
- CRESWELL, J. W.; CRESWELL, J. D. **Research design: qualitative, quantitative, and mixed methods approaches**. 5. ed. Thousand Oaks: SAGE, 2018.
- D'ACUNTO, F.; PRABHALA, N.; ROSSI, A. G. The promises and pitfalls of robo-advising. **The Review of Financial Studies**, v. 32, n. 5, p. 1983–2020, 2019.
- DISTRITO FEDERAL. **Lei Distrital nº 2.834, de 7 de dezembro de 2001. Dispõe sobre o processo administrativo no âmbito da administração pública do Distrito Federal**. Brasília: CLDF, 2001.
- EVANS, P.; RAUCH, J. E. Bureaucracy and growth: a cross-national analysis of the effects of 'Weberian' state structures on economic growth. **American Sociological Review**, v. 64, n. 5, p. 748–765, 1999.
- HEVNER, A. R. et al. Design science in information systems research. **MIS Quarterly**, v. 28, n. 1, p. 75–105, 2004.
- LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: **ADVANCES in Neural Information Processing Systems (NeurIPS)**. [S.l.: s.n.], 2020. v. 33, p. 9459–9474.

LOPEZ-LIRA, A.; TANG, Y. **Can ChatGPT forecast stock price movements?** 2023. arXiv: 2304.07619.

RESOLUÇÃO CMN nº 4.557, de 23 de fevereiro de 2017. Dispõe sobre a estrutura de gerenciamento de riscos e de capital. Brasília: Banco Central do Brasil, 2017.

RESOLUÇÃO CMN nº 4.879, de 23 de dezembro de 2020. Regulamenta a atividade de auditoria interna nas instituições autorizadas a funcionar pelo Banco Central do Brasil. Brasília: Banco Central do Brasil, 2020.

RESOLUÇÃO CMN nº 4.893, de 26 de fevereiro de 2021. Dispõe sobre a política de segurança cibernética. Brasília: Banco Central do Brasil, 2021.

RESOLUÇÃO CMN nº 4.968, de 25 de novembro de 2021. Regulamenta os sistemas de controles internos das instituições financeiras. Brasília: Banco Central do Brasil, 2021.

RESOLUÇÃO CMN nº 5.274, de 18 de dezembro de 2025. Altera a Resolução CMN nº 4.893/2021 sobre política de segurança cibernética. Brasília: Banco Central do Brasil, 2025.

RESOLUÇÃO CVM nº 30, de 11 de maio de 2021. Dispõe sobre o dever de verificação da adequação dos produtos, serviços e operações ao perfil do cliente (suitability). Rio de Janeiro: CVM, 2021.

RÍMOLI, T. T.; MELO, D. d. C. A voz dos consumidores em redes sociais: proposição de um modelo eficaz de gestão de reclamações às empresas. **ReMark – Revista Brasileira de Marketing**, v. 17, n. 1, p. 49–64, 2018.

SAURO, J. **A practical guide to the System Usability Scale (SUS): background, benchmarks and best practices**. Denver: Measuring Usability LLC, 2011.

SCHICK, T. et al. **Toolformer: language models can teach themselves to use tools**. 2023. arXiv: 2302.04761.

SENADO FEDERAL. **Projeto de Lei nº 2.338, de 2023. Estabelece normas gerais sobre desenvolvimento, implementação e uso responsável de sistemas de inteligência artificial no Brasil**. Brasília: Senado Federal, 2023.

STIGLITZ, J. E.; WEISS, A. Credit rationing in markets with imperfect information. **The American Economic Review**, v. 71, n. 3, p. 393–410, 1981.

SUPERIOR TRIBUNAL DE JUSTIÇA. **Súmula nº 297. O Código de Defesa do Consumidor é aplicável às instituições financeiras**. Brasília: STJ, 2004.

ANEXOS

ANEXO I – CRONOGRAMA DA PESQUISA (CONFORME PLANEJADO NO PRÉ-PROJETO)

A seguir apresenta-se a descrição detalhada das atividades de pesquisa planejadas para o período de 2026-2027. A janela de backtesting foi delimitada a 12 meses (jun/2025–mai/2026), em ambiente de relevante volatilidade macroeconômica na curva de juros brasileira, com disponibilidade integral de dados históricos para os produtos avaliados.

Quadro 7.1 – Descritivo de Atividades e Prazos de Entrega

Atividades de Pesquisa	Ago/26	Set/26	Out/26	Nov/26	Dez/26	Jan/27	Fev/27	Mar/27	Abr/27	Mai/27
Início da orientação	•									
Diagnóstico – mapeamento via bases públicas online	•	•	•							
Engenharia de ferramentas Python/APIs		•	•	•	•					
Orquestração do agente (function calling) + logs XAI			•	•	•	•				
Construção base RAG normativos				•	•					
Backtesting 12 meses (jun/25–mai/26)					•	•	•			
Exame de qualificação								•		
Validação – avaliação técnica especialistas							•	•		
Validação – usabilidade gerentes								•	•	
Compilação dos resultados									•	•
Escrita do capítulo empírico									•	•
Previsão de defesa da dissertação										•
Depósito da versão final										•
Elaboração do artigo científico							•	•	•	•

Fonte: Elaborado pelo autor (2026).

ANEXO II – PERSONAS SINTÉTICAS DE INVESTIDOR

[Pendente – fichas das personas construídas a partir dos quatro perfis do Raio X do Investidor Brasileiro (ANBIMA, 2025): Diversifica, Caderneta, Economiza e Não Investe, Sem Reservas.]

ANEXO III – INSTRUMENTO DE AVALIAÇÃO TÉCNICA

[Pendente – rubrica Likert de 5 pontos: fidelidade do RFL, aderência à Resolução CVM nº 30/2021 e clareza da linguagem.]

ANEXO IV – QUESTIONÁRIO SUS

[Pendente – System Usability Scale, 10 itens, aplicado aos gerentes de front-office do BRB.]